

Titanic en Kaggle

Gerardo González

28-08-2026

Desarrollo de soluciones inteligentes

Universidad Bernardo O'Higgins

1. Resumen Ejecutivo y Resultados Métricos

Se entrenaron y evaluaron dos modelos de clasificación (Regresión Logística y Random Forest) utilizando la misma partición de validación local (80% entrenamiento, 20% validación estratificada con `random_state=42`) y el mismo pipeline de preparación de datos.

	Modelo	Accuracy	Precision	Recall	F1
0	Regresión Logística	0.804469	0.793103	0.666667	0.724409
1	Random Forest	0.815642	0.781250	0.724638	0.751880

Selección final: Se selecciona Random Forest debido a su superioridad en Recall (72.46% vs 66.67%) y F1-Score (0.7519 vs 0.7244), demostrando mayor equilibrio y capacidad para detectar sobrevivientes reales.

2. Análisis Comparativo e Interpretación de Resultados

Interpretación de Falsos Positivos y Falsos Negativos

Falsos Positivos (FP): Son pasajeros que el modelo predijo que sobrevivieron, pero que lamentablemente fallecieron. En este contexto representa una sobreestimación de supervivencia.

Falsos Negativos (FN): Son pasajeros que el modelo predijo que fallecieron, pero que en realidad sobrevivieron. La Regresión Logística tuvo 23 FN, mientras que Random Forest los redujo a 19.

Métrica a Priorizar

Se prioriza el F1-Score o el Recall. Al estar los datos desbalanceados con más fallecidos que sobrevivientes, la meta es minimizar los Falsos Negativos para no perder de vista a la clase

minoritaria. El F1-Score de 0.7519 en Random Forest contra 0.7244 en Regresión Logística muestra un mejor equilibrio entre precisión y detección de sobrevivientes reales.

¿Es suficiente el Accuracy?

No, no es suficiente. El Accuracy de 81.56% indica el porcentaje total de aciertos globales, pero resulta engañoso si el modelo se enfoca solo en la clase mayoritaria de fallecidos. Un modelo puede tener un porcentaje alto acertando los fallecidos, pero fallar al detectar a los sobrevivientes.

Comparación entre Validación Local y Puntaje en Kaggle

Validación Local: 81.56% Public Score en Kaggle: 75.36%

Discusión: Existe una diferencia de 6 puntos porcentuales. Esto ocurre debido a un leve sobreajuste (overfitting) del modelo a los datos de entrenamiento local, o bien a que la distribución de los datos de prueba no vistos en Kaggle presenta diferencias sutiles respecto al conjunto de validación.

3. Evidencia de Envío a Kaggle

Puntaje Público (Public Score) obtenido en Kaggle: 0.75358

The screenshot displays the Kaggle website interface for the "Titanic - Machine Learning from Disaster" competition. The browser's address bar shows the URL www.kaggle.com/competitions/titanic/submissions. The page features a sidebar with navigation icons and a main content area. The competition title "Titanic - Machine Learning from Disaster" is prominently displayed, along with a "Submit Prediction" button. Below the title, a navigation bar includes links for Overview, Data, Code, Models, Discussion, Leaderboard, Rules, Team, and Submissions. The "Submissions" tab is active, showing a list of submissions. The first submission, named "submission.csv", is highlighted with a green checkmark icon. It is described as "Complete - 24s to go - Modelo Random Forest" and has a public score of 0.75358. The page also includes a footer with a cookie notice and system information.

Kaggle uses cookies from Google to deliver and enhance the quality of its services and to analyze traffic. [Learn more](#) [OK, Got it.](#)

ESP LAA 14:44 28-08-2026

4. Declaración de uso de IA Generativa

Utilicé herramientas de Inteligencia Artificial (ChatGPT y Gemini) como asistentes de apoyo técnico para las siguientes tareas:

ChatGPT: Se utilizó para proponer y explicar la estructura inicial del código en el notebook, apoyar en la depuración y guiar el flujo general del trabajo (preparación de datos, entrenamiento, evaluación y generación de predicciones).

Gemini: Se utilizó como soporte técnico para la resolución de errores específicos de entorno de ejecución en Kaggle (rutas de archivo e índices), optimización del pipeline de datos y redacción técnica estructurada para el informe final.

Control y verificación humana:

Verifiqué cada bloque de código mediante su ejecución directa en el entorno de Kaggle y la validación de sus salidas numéricas.

Tomé las decisiones metodológicas humanas respecto a la selección de variables predictoras, la estrategia de imputación de medianas, la interpretación de las matrices de confusión y el análisis comparativo para la selección del modelo final.